

Phiếu Bài Tập Về Nhà (Problem Set 03)

Môn học: Xác suất Thống kê (UET.MAT1052)

Chủ đề: Ngữ Pháp Đồ Họa, Thao Tác Dữ Liệu & Nghịch Lý Simpson

(Grammar of Graphics, Data Wrangling & Simpson's Paradox)

Thời hạn nộp: Trước buổi học Tuần 04.

Hình thức nộp: Nộp báo cáo tập Word (.docx), PDF hoặc xuất từ Jupyter Notebook (.ipynb).

Dữ liệu thực hành: `du-lieu/us_births.csv` và `du-lieu/penguins.csv`.

BÀI 1: NGỮ PHÁP ĐỒ HỌA & PHÂN TÍCH CHUỖI DỮ LIỆU SỐ CA SINH (US

BIRTHS) (2.5 ĐIỂM) Tập dữ liệu `us_births.csv` ghi nhận số ca sinh hàng ngày tại Hoa Kỳ trong giai đoạn 1969 – 1988 (gồm 7,305 ngày quan sát). Khi trực quan hóa số lượng ca sinh theo thời gian, việc lựa chọn dạng hình học (Geometries) và thuộc tính thẩm mỹ (Aesthetics) ảnh hưởng trực tiếp đến thông điệp thu được.

Yêu cầu: 1. (0.5 điểm) **Biểu diễn hình học:** So sánh sự khác biệt về khả năng truyền tải thông tin giữa biểu đồ phân tán (Scatter plot - `geom_point`) và biểu đồ đường nối liên tục (Line plot - `geom_line`) khi phân tích dữ liệu chuỗi thời gian có tần suất dày đặc như `us_births`. Dạng biểu đồ nào làm lộ rõ tính phân mảnh và phân nhóm của dữ liệu hơn? 2. (1.0 điểm) **Hiện tượng chu kỳ tuần:** Trên biểu đồ phân tán số ca sinh theo ngày trong năm, quan sát thấy hai dải điểm phân tách chạy song song nhau. Hãy giải thích: - Hai dải điểm này phản ánh hiện tượng gì trong chu kỳ tuần? - Cơ chế y tế và hành vi xã hội nào (liên quan đến lịch mổ lấy thai chủ động C-section và kích sinh) tạo nên sự phân tách này giữa các ngày làm việc (Thứ 2 – Thứ 6) và hai ngày cuối tuần (Thứ 7 – Chủ Nhật)? 3. (0.5 điểm) **Sự kiện dị thường:** Quan sát chuỗi số liệu tại các mốc ngày lễ lớn như: Tết Dương lịch (1/1), Ngày Quốc khánh Mỹ (4/7), Lễ Tạ ơn (Thanksgiving) và Lễ Giáng sinh (25/12). Số lượng ca sinh tại các ngày này biến động như thế nào so với các ngày lân cận? Tại sao? 4. (0.5 điểm) **Mã lệnh plotnine:** Viết đoạn code Python ngắn sử dụng thư viện plotnine (`ggplot`, `aes`, `geom_point`) để vẽ biểu đồ phân tán số ca sinh (`births`) theo ngày trong năm (`day_of_year`), trong đó các điểm được tô màu (`color`) dựa trên biến ngày trong tuần (`wday`).

BÀI 2: MAPPING VS SETTING & TRỰC QUAN HÓA PLOTNINE ĐA CHIỀU (2.0

ĐIỂM) Ngữ pháp đồ họa phân biệt rạch ròi giữa việc liên kết biến dữ liệu với kênh thị giác (**Aesthetic Mapping**) và việc thiết lập thuộc tính hiển thị tĩnh (**Property Setting**).

Yêu cầu: 1. (0.5 điểm) **Bản chất kỹ thuật:** Phân biệt rõ sự khác nhau giữa Mapping và Setting trong thư viện plotnine. Nêu ý nghĩa của việc khai báo bên trong `aes(color='species')` so với việc khai báo ngoài hàm hình học `geom_point(color='steelblue')`. 2. (0.5 điểm) **Gỡ lỗi (Debugging):** Một sinh viên muốn vẽ biểu đồ phân tán giữa chiều dài mỏ (`bill_length_mm`) và độ sâu mỏ (`bill_depth_mm`) của chim cánh cụt với màu sắc phân biệt theo loài (`species`), bạn ấy viết câu lệnh: `python # Đoạn mã của sinh viên: ggplot(penguins, aes(x='bill_length_mm', y='bill_depth_mm')) + geom_point(color='species')` Lệnh trên có chạy thành công không?

Nếu lỗi hoặc cho kết quả sai, hãy giải thích nguyên nhân và viết lại câu lệnh chính xác. 3. (1.0 điểm) **Chuẩn mực trình bày biểu đồ:** Viết một đoạn mã Python hoàn chỉnh sử dụng `plotnine` thực hiện các yêu cầu sau: - Vẽ biểu đồ phân tán hiển thị mối quan hệ giữa `bill_length_mm` (trục hoành) và `bill_depth_mm` (trục tung). - Ánh xạ loài (`species`) vào màu sắc (`color`) và kích thước điểm (`size`) vào khối lượng cơ thể (`body_mass_g`) bên trong `aes()`. - Cấu hình tiêu đề, nhãn trục tiếng Việt rõ ràng kèm đơn vị đo chuẩn thông qua lớp `labs()` mà **không làm thay đổi tên cột gốc** của DataFrame.

BÀI 3: DÂY CHUYỀN SPLIT - APPLY - COMBINE TRÊN PALMER PENGUINS (2.0

ĐIỂM) Tập dữ liệu Palmer Penguins ghi nhận số đo hình thái sinh học của 3 loài chim cánh cụt (Adelie, Chinstrap, Gentoo) thu thập trên 3 hòn đảo thuộc quần đảo Palmer, Nam Cực.

Yêu cầu: 1. (0.75 điểm) **Dây chuyền tính toán theo nhóm:** Viết câu lệnh Pandas sử dụng phương thức `groupby(['species', 'island'])` kết hợp với `.agg()` để tạo ra một bảng thống kê tóm tắt gồm: - Số cá thể quan sát được (`count`). - Khối lượng cơ thể trung bình (`mean`) của biến `body_mass_g`. - Độ lệch chuẩn (`std`) của biến `body_mass_g` (hiệu chỉnh mẫu $N - 1$). 2. (0.75 điểm) **Điều kiện hóa (Conditioning):** Sử dụng phương thức `.query()` hoặc boolean indexing trong Pandas để trích xuất các cá thể chim cánh cụt thỏa mãn đồng thời hai điều kiện: - Thuộc loài Gentoo hoặc Adelie. - Có khối lượng cơ thể lớn hơn 4,200 g và sinh sống tại đảo Biscoe. 3. (0.5 điểm) **Phân tích địa lý sinh thái:** Dựa trên kết quả thống kê ở câu 1, hãy nêu nhận xét về sự phân bố của 3 loài chim cánh cụt trên 3 hòn đảo (Biscoe, Dream, Torgersen). Loài nào phân bố rộng khắp trên cả 3 đảo, và loài nào chỉ xuất hiện độc quyền tại một hòn đảo duy nhất?

BÀI 4: KHÁM PHÁ & MÔ HÌNH HÓA NGHỊCH LÝ SIMPSON (SIMPSON'S PARADOX)

(2.5 ĐIỂM) Nghịch lý Simpson là hiện tượng thống kê nguy hiểm trong phân tích dữ liệu, khi một xu hướng hoặc mối quan hệ quan sát được trong từng nhóm nhỏ bị đảo ngược hoặc triệt tiêu khi gộp chung toàn bộ dữ liệu.

Phần 1: Dữ liệu Palmer Penguins (1.5 điểm)

Xét tiêu chí phân loại cá thể “cân nặng lớn”: khối lượng cơ thể `body_mass_g` > 4,000 g. 1. (0.5 điểm) Khi gộp chung toàn bộ 342 cá thể chim cánh cụt hợp lệ trong tập dữ liệu, hãy tính tỷ lệ phần trăm cá thể có cân nặng lớn hơn 4,000 g. 2. (0.5 điểm) Tính tỷ lệ phần trăm cá thể có cân nặng lớn hơn 4,000 g khi tách riêng cho từng loài: - Loài Adelie ($n = 151$). - Loài Chinstrap ($n = 68$). • Loài Gentoo ($n = 123$). 3. (0.5 điểm) So sánh tỷ lệ gộp chung

với tỷ lệ riêng của từng loài. Tại sao tỷ lệ gộp chung ($\approx 50.3\%$) lại thấp hơn rất nhiều so với loài Gentoo (99.2%) nhưng lại cao hơn gấp đôi so với Adelie (23.2%) và Chinstrap (22.1%)? Đây là biến ẩn (Confounder) chi phối hiện tượng này?

Phần 2: Ứng dụng Kỹ thuật Phần mềm - Đánh giá Hiệu năng Hệ thống

(1.0 điểm) Một đội ngũ SRE (Site Reliability Engineering) thử nghiệm hai cụm máy chủ: **Cluster A (Hệ thống cũ)** và **Cluster B (Hệ thống thế hệ mới)**. Trong đợt kiểm thử, mỗi cụm nhận đúng 1,000 requests. Các request được chia làm hai loại: - **Lightweight requests:** Các truy vấn lấy dữ

liệu từ bộ nhớ cache nhanh. - **Heavyweight requests:** Các tác vụ tính toán máy học và truy vấn cơ sở dữ liệu nặng.

Số liệu thống kê tỷ lệ request có thời gian phản hồi nhanh (< 50 ms) như sau: - **Với Lightweight requests:** - Cluster B đạt tỷ lệ phản hồi nhanh là **90%** (180/200 requests). - Cluster A đạt tỷ lệ phản hồi nhanh là **80%** (720/900 requests). - **Với Heavyweight requests:** - Cluster B đạt tỷ lệ phản hồi nhanh là **30%** (240/800 requests). - Cluster A đạt tỷ lệ phản hồi nhanh là **20%** (20/100 requests).

Yêu cầu: - a) Tính tỷ lệ phản hồi nhanh gộp chung trên toàn bộ 1,000 requests của Cluster A và Cluster B. - b) Chỉ ra hiện tượng nghịch lý: Cụm máy chủ nào hoạt động vượt trội hơn trên từng loại request? Nhưng cụm nào lại có tỷ lệ phản hồi nhanh gộp chung cao hơn? Giải thích nguyên nhân gốc rễ và bài học rút ra khi đánh giá hiệu năng hệ thống phân tán.

BÀI 5: TƯ DUY PHẢN BIỆN & THIẾT KẾ DỮ LIỆU CÓ TRÁCH NHIỆM (1.0 ĐIỂM)

Trong vai trò là một Kỹ sư Dữ liệu (Data Engineer) hoặc Nhà khoa học Dữ liệu (Data Scientist) thiết kế Dashboard giám sát KPI hoặc phân tích kết quả thử nghiệm A/B Testing: 1. (0.5 điểm) Nếu một giám đốc sản phẩm kết luận rằng: “*Thuật toán gợi ý B kém hơn thuật toán A vì tỷ lệ chuyển đổi (Conversion Rate) tổng thể của B thấp hơn A*”, bạn sẽ đặt ra câu hỏi phản biện gì về cơ cấu phân bổ người dùng (User Segmentation)? 2. (0.5 điểm) Đề xuất ít nhất hai nguyên tắc thực hành (Best Practices) giúp đội ngũ kỹ thuật tránh rơi vào cái bẫy của Nghịch lý Simpson khi trực quan hóa và báo cáo số liệu.